



1강. Physical AI 개요와 연산 분담



학습 목표

- Physical AI가 무엇인지, 소프트웨어 AI와 근본적으로 어떻게 다른지 설명할 수 있습니다.
- 로봇의 연산이 임베디드·Edge AI·클라우드 세 계층으로 나뉘는 이유를 지연·연산량·대역폭 관점에서 설명할 수 있습니다.
- 특정 작업을 어느 계층에서 처리할지 **지연 예산(latency budget)** 과 **데이터 전송량**을 근거로 판단할 수 있습니다.
- 모든 연산을 클라우드에 두지 않는 이유(지연·대역폭·가용성·프라이버시)를 설명할 수 있습니다.



목차

들어가며

1. Physical AI란 무엇일까요?
2. 연산은 왜 나누어 처리할까요?
3. 세 계층은 각각 무엇을, 어떤 하드웨어로 담당할까요?
4. 판단의 핵심 ① — 지연 예산(latency budget)

간단한 계산 예시

5. 판단의 핵심 ② — 데이터 전송량과 대역폭
6. 왜 전부 클라우드에 두지 않을까요?
7. 실생활 시나리오로 통합하기

미니 퀴즈

실습

정리

들어가며

여러분이 로봇 청소기를 사용한다고 생각해 보겠습니다. 청소기는 계단 앞에서 **즉시** 멈춰야 합니다. 이 판단이 0.3초만 늦어도 로봇은 굴러떨어집니다. 반면 "이 집의 평면도를 학습해 가장 효율적인 청소 경로를 계산"하는 작업은 몇 초가 걸려도 괜찮고, 심지어 로봇이 충전 중일 때 처리해도 됩니다.

같은 로봇 안에서도 **어떤 계산은 밀리초 안에 끝나야 하고, 어떤 계산은 몇 초의 여유가 있습니다.** 이 차이를 이해하고 연산을 알맞은 곳에 배치하는 것이 Physical AI 시스템 설계의 출발점입니다. 이번 강의에서는 그 "알맞은 곳"을 판단하는 기준을 정량적으로 익히겠습니다.

1. Physical AI란 무엇일까요?

Physical AI는 물리적 세계에서 직접 **인지하고(perceive)**, **판단하고(decide)**, **행동하는(act)** 인공지능입니다. ChatGPT 같은 소프트웨어 AI가 텍스트를 입력받아 텍스트를 출력하는 데 그친다면, Physical AI는 **센서로 세상을 읽고 모터로 세상에 힘을 가합니다.** 이 "물리적 몸을 통한 페루프"가 결정적 차이를 만듭니다.

구분	소프트웨어 AI (예: 챗봇)	Physical AI (예: 로봇)
입력	텍스트·이미지 (디지털)	센서 신호 (물리량)
출력	텍스트·이미지 (디지털)	모터 구동 (물리적 힘)
시간 제약	수 초 지연 허용	밀리초 단위 마감 존재
실패의 결과	잘못된 답변	충돌·낙하·사고
실행 환경	대형 GPU 서버	제한된 온보드 컴퓨터

이 표에서 보이듯, Physical AI에는 소프트웨어 AI에 없는 세 가지 제약이 있습니다.

- **실시간성:** 물리 세계는 기다려 주지 않습니다. 로봇이 넘어지는 중이라면 정책 계산이 늦어선 안 됩니다.
- **안전성:** 잘못된 출력이 실제 사고로 이어집니다. 그래서 **안전을 담당하는 계층은 절대 느려지면 안 됩니다.**
- **자원 제약:** 로봇에 탑재된 컴퓨터는 데이터센터의 GPU 서버만큼 강력하지 않고, 전력·발열·무게 제약까지 받습니다.

바로 이 세 제약 때문에, Physical AI는 연산을 **여러 계층에 나누어** 처리합니다.

2. 연산은 왜 나누어 처리할까요?


로봇의 모든 계산을 한 곳에서 처리하면 어떻게 될까요? 양극단을 생각해 보면 답이 보입니다.

- **모든 걸 로봇 안의 작은 칩에서 처리하면** → 무거운 AI 연산(이미지 인식, 대규모 지도 처리)을 감당하지 못합니다.

- 모든 걸 클라우드 서버로 보내 처리하면 → 네트워크 왕복 지연 때문에 즉각 반응이 불가능하고, 통신이 끊기면 로봇이 멈춰 버립니다.

그래서 로봇 시스템은 연산을 **임베디드 · Edge AI · 클라우드** 세 계층으로 나눕니다. 각 계층은 담당하는 작업의 성격이 다릅니다.

로봇 연산의 3계층 분담



images/01_연산분담_3계층.png — 로봇 연산의 3계층 분담

💡 **해석:** 로봇 본체 안에는 임베디드(MCU)와 Edge AI(온보드 컴퓨터)가 함께 있고, 클라우드는 네트워크 너머에 있습니다. 센서에 가까울수록 빠르게(임베디드), 연산이 무거울수록 멀리(클라우드) 보냅니다. **안쪽으로 갈수록 지연이 짧고, 바깥으로 갈수록 연산 능력이 큼니다.**

3. 세 계층은 각각 무엇을, 어떤 하드웨어로 담당할까요?


각 계층의 역할과 대표 하드웨어를 구체적으로 살펴보겠습니다.

계층	대표 하드웨어	담당 작업	지연
임베디드	MCU (STM32, Cortex-M)	모터 제어 루프, 센서 읽기, 안전 정지 (E-Stop)	마이크로초~밀리초
Edge AI	Jetson Orin, 온보드 x86 PC	객체 인식, 센서 융합, 지역 경로 계획, SLAM	밀리초~수십 밀리초
클라우드	GPU 서버 클러스터	모델 학습, 대규모 지도 생성, 원격 모니터링·업데이트	수백 밀리초~초

핵심 판단 기준은 "이 작업이 얼마나 빨리 끝나야 하는가(지연 요구)" 와 "얼마나 무거운 연산인가(연산량)" 입니다.

- 넘어짐 방지, 충돌 회피처럼 **즉각 반응**이 필요하면 → 임베디드
- 카메라로 사람을 인식하는 것처럼 **실시간 AI** 추론이면 → Edge AI
- 수집한 데이터로 **모델을 재학습**하는 것처럼 무겁고 급하지 않으면 → 클라우드

작업 성격에 따른 계층 배치



images/01_지연_스펙트럼.png — 작업 성격에 따른 계층 배치

💡 **해석:** 왼쪽으로 갈수록 즉각 반응이 필요한 작업(임베디드), 오른쪽으로 갈수록 무겁지만 급하지 않은 작업(클라우드)입니다. 같은 로봇의 작업이라도 **요구 속도**와 **연산량에 따라 배치되는 계층이 달라집니다.**

4. 판단의 핵심 ① — 지연 예산(latency budget)

"제때"의 기준을 정량적으로 잡아 보겠습니다. 어떤 제어가 **최대 얼마의 지연까지 허용되는지**를 정한 것을 **지연 예산**이라 합니다. 그리고 실제 시스템의 지연은 여러 단계가 **누적**된 합입니다.

엔드-투-엔드 지연 예산 비교

같은 제어라도 '어디서 계산하느냐'에 따라 지연이 수백 배 차이납니다



💡 **해석:** 같은 "센서 → 판단 → 제어" 흐름이라도, 로컬(임베디드)에서 처리하면 약 **1ms**대로 끝나지만, 클라우드로 왕복하면 수백 ms가 됩니다. 네트워크 전송(업/다운)과 원격 추론이 지연의 대부분을 차지하기 때문입니다. 만약 이 제어의 지연 예산이 "5ms 이내"라면, 클라우드 경로는 **예산을 100배 초과**하므로 애초에 후보가 될 수 없습니다.

간단한 계산 예시

바퀴 모터를 1kHz(1ms 주기)로 제어한다고 합시다. 한 주기 안에 "센서 읽기 → 계산 → 모터 출력"이 모두 끝나야 하므로, 이 루프의 지연 예산은 **1ms 미만**입니다.

- 임베디드에서 처리: 센서 0.5ms + 계산 0.3ms + 출력 0.4ms $\approx$ **1.2ms** → 아슬아슬하지만 로컬에서 가능
- 클라우드로 왕복: 왕복 전송만 80ms + 추론 60ms $\approx$ **140ms** → 예산의 100배 초과, 불가능

이처럼 지연 예산은 어떤 작업을 어느 계층에 둘지 결정하는 1차 필터입니다.

5. 판단의 핵심 ② — 데이터 전송량과 대역폭

지연만큼 중요한 것이 "**얼마나 많은 데이터를 옮겨야 하는가**"입니다. 카메라·라이다 같은 센서는 엄청난 양의 데이터를 쏟아냅니다.

- 1080p 30fps 컬러 영상(무압축): 약 **1920×1080×3바이트×30 $\approx$ 187MB/s**
- 3D 라이다: 초당 수십만~수백만 점(point)

이 원시 데이터를 **매번 클라우드로 올리는 것은 비현실적**입니다. 네트워크 대역폭이 부족하고 비용도 큼니다. 그래서 원칙은 이렇습니다.

- ✓ **원칙:** 데이터는 발생한 곳 근처에서 처리하고, 결과(요약)만 상위 계층으로 보낸다.

예를 들어 카메라 영상 전체를 클라우드로 보내는 대신, **Edge AI가 영상에서 "사람이 (x, y)에 있다"는 결과만 추출**해 상위로 보냅니다. 187MB/s가 몇 바이트로 줄어드는 셈입니다.

6. 왜 전부 클라우드에 두지 않을까요?

클라우드가 가장 강력한데, 왜 로봇은 임베디드·Edge를 함께 둘까요? 네 가지 이유가 있습니다.

- **지연**: 네트워크 왕복(수십~수백 ms)은 실시간 제어에 치명적입니다.
- **대역폭**: 원시 센서 데이터를 전부 올리기엔 통신량이 너무 큼니다.
- **가용성**: 통신이 끊기면 클라우드 의존 로봇은 멈춥니다. 하지만 **안전 정지 같은 기능은 통신과 무관하게 항상 동작해야** 합니다.
- **프라이버시·비용**: 가정·병원의 영상을 외부로 계속 보내는 것은 프라이버시 문제가 되고, 전송·연산 비용도 누적됩니다.
- ▶ **심화** — 연산 오프로딩(offloading)과 모델 분할(model partitioning)

7. 실생활 시나리오로 통합하기

자율주행 배달로봇이 골목을 지나는 상황을 세 계층으로 나눠 보겠습니다.

- **임베디드**: 바퀴 모터 속도를 목표값에 맞추고(1kHz 제어 루프), 범퍼 센서가 눌리면 통신 상태와 무관하게 **즉시 정지**시킵니다.
- **Edge AI**: 전방 카메라·라이다를 융합해 보행자·장애물을 인식하고, 다음 몇 초의 지역 경로를 계획합니다(수십 Hz). 원시 영상은 여기서 소비하고 **"장애물 위치" 같은 요약만** 남깁니다.
- **클라우드**: 로봇이 하루 동안 다닌 경로·이벤트 데이터를 모아, 밤사이 **배달 경로 최적화 모델을 재학습**하고 다음 날 로봇들에 배포합니다.

이렇게 나누면 각 작업이 **요구 지연과 연산량에 딱 맞는 곳**에서 처리되어, 로봇이 안전하면서도 똑똑하게 동작합니다.

미니 퀴즈

💡 아래 문항을 **먼저 스스로 풀어 본 뒤** 실습으로 넘어가세요. 답안은 실습 결과물과 함께 제출합니다. (총 10점)

1. (2점) 소프트웨어 AI와 비교할 때 Physical AI의 특징으로 **틀린** 것은?

- ① 입력이 센서 신호(물리량)이다
- ② 밀리초 단위 마감이 존재한다
- ③ 실패가 물리적 사고로 이어질 수 있다
- ④ 항상 대형 GPU 서버에서 실행된다

2. (2점) 다음 작업을 담당 계층(임베디드 / Edge / 클라우드)으로 각각 분류하세요.

(가) 모터 전류 제어 루프 (나) 카메라 객체 인식 (다) 딥러닝 모델 학습

3. (2점) 어떤 안전 정지 기능의 마감이 10 ms 입니다. 왕복 네트워크 지연만 60 ms 인 클라우드에 이 기능을 두면 안 되는 이유를 **두 가지** 쓰세요.

4. (2점) 참/거짓: 대역폭이 충분하면 모든 연산을 클라우드로 올리는 것이 항상 유리하다.

5. (2점) 지연 예산(latency budget)이란 무엇인지 한 문장으로 설명하세요.

실습

시판 로봇 1종(로봇청소기·배달로봇·드론 등)을 하나 골라, 그 로봇이 수행하는 작업 5가지를 적고 각각을 어느 계층에서 처리해야 할지 **지연 예산과 데이터 전송량을 근거로** 분류해 보겠습니다.

작업	처리 계층	지연 요구	데이터량	근거
예) 낙하 방지 정지	임베디드	< 10ms	매우 작음	즉시 반응 필요, 통신 끊겨도 동작함

정답이 하나로 정해져 있지는 않습니다. **왜 그 계층을 선택했는지, 지연·데이터·가용성 관점에서 근거를 설명하는 것이** 이 실습의 핵심입니다.

정리

- Physical AI는 물리 세계에서 인지-판단-행동하는 AI이며, **실시간성·안전성·자원 제약**이라는 고유한 제약이 있습니다.
- 로봇 연산은 **임베디드(초저지연) → Edge AI(실시간 추론) → 클라우드(대규모 연산)** 세 계층으로 나뉩니다.
- 작업을 배치하는 1차 기준은 **지연 예산**(누적 지연의 합)과 **데이터 전송량**입니다.
- 클라우드가 가장 강력하지만, **지연·대역폭·가용성·프라이버시** 때문에 모든 연산을 클라우드에 둘 수는 없습니다. 원칙은 **"데이터는 근처에서 처리하고 요약만 올린다"**입니다.

